TP_TextMining_Thai-AnThanTrong

December 8, 2017

1 Setup

```
texts = texts_neg + texts_pos
y = np.ones(len(texts), dtype=np.int)
y[:len(texts_neg)] = 0.

print("%d documents" % len(texts))

Loading dataset
2000 documents
```

2 IMPLEMENTATION DU CLASSIFIEUR

2.1 Question 1

Compléter la fonction count_words qui va compter le nombre d'occurrences de chaque mot dans une liste de string et renvoyer le vocabulaire

```
In [4]: def count_words(texts):
            """Vectorize text : return count of each word in the text snippets
            Parameters
            _____
            texts : list of str
                The texts
            Returns
            vocabulary : dict
                A dictionary that points to an index in counts for each word.
            counts: ndarray, shape (n_samples, n_features)
                The counts of each word in each text.
                n_samples == number of documents.
                n\_features == number of words in vocabulary.
            words = set(' '.join(texts).split())
            n_features = len(words)
            n_samples = len(texts)
            counts = np.zeros((n_samples, n_features))
            # Build vocabulary dictionary - key : word , value : column index in counts array
            vocabulary = { word : i for i, word in enumerate(sorted(words)) }
            # Build counts
            for 1, text in enumerate(texts, 0):
                st = text.split()
                for w in st:
```

```
counts[1, vocabulary[w]] +=1
return vocabulary, counts
```

2.1.1 Test sur un jeu de données simple

On teste dans un premier temps sur un petit jeu de données.

```
In [5]: # Test on a small text
       text_sample = ["Hello world", "Hello Telecom and world",
                       "Hello I love Christmas", "Christmas is coming",
                      "Christmas is cool and fun"]
       vocabulary_sample, X_sample = count_words(text_sample)
       print("--- Vocabulary sample")
       print(vocabulary_sample)
       import pandas as pd
       df_sample = pd.DataFrame(X_sample, columns=sorted(vocabulary_sample))
       print()
       print("--- X sample")
       print(df_sample)
--- Vocabulary sample
{'fun': 7, 'cool': 6, 'Christmas': 0, 'coming': 5, 'love': 9, 'Telecom': 3, 'world': 10,
 'is': 8, 'Hello': 1, 'I': 2, 'and': 4}
--- X sample
  Christmas Hello
                      I Telecom and coming cool
                                                     fun
                                                           is love world
0
        0.0
               1.0 0.0
                             0.0 0.0
                                          0.0
                                                0.0 0.0 0.0
                                                                0.0
                                                                       1.0
        0.0
               1.0 0.0
                             1.0 1.0
                                          0.0
                                                0.0 0.0 0.0
                                                                0.0
                                                                       1.0
1
2
        1.0
               1.0 1.0
                             0.0 0.0
                                          0.0
                                                0.0 0.0 0.0
                                                                1.0
                                                                       0.0
3
                             0.0 0.0
                                          1.0
                                                                       0.0
        1.0
               0.0 0.0
                                                0.0 0.0 1.0
                                                                0.0
4
        1.0
               0.0 0.0
                             0.0 1.0
                                          0.0
                                                1.0 1.0 1.0
                                                                0.0
                                                                       0.0
```

2.1.2 Application sur les données réelles

```
In [6]: # Count words in texts
    vocabulary, X = count_words(texts)
```

2.2 Question 2

Expliquer comment les classes positives et négatives ont été assignées sur les critiques de film.

D'après le fichier poldata.README.2.0, les analyses peuvent ne pas avoir explicitement de note. Dans le cas où il existe une note, celle-ci peut apparaître à différents sendroits du fichiers et sous différentes formes. Dans le cas de nos données on se focalie uniquement sur les notations les plus explicites, issues d'un set de règles ad-hoc. La classification d'un fichier est donc établie à partir de la première note dont on est capable d'identifier.

- Avec un système de cinq étoiles (ou un système numérique équivalent), plus de 3.5 étoiles mènent à une critique positive, et moins de 2 stars mènent à une critique négative.
- Avec un systèmes de quatre étoies (ou un système numérique équivalent), plus de 3 stars mènentà une critique positives, et moins de 1.5 stars mènent à une critique négative.
- Avec un systèmes constitué de lettres, B ou au-dessus mène à une critique positive, et C- ou en-dessous est considéré comme négatif.

2.3 Ouestion 3

Compléter la classe NB pour qu'elle implémente le classifieur Naive Bayes.

```
In [7]: class NB(BaseEstimator, ClassifierMixin):
            def __init__(self, smoothing=1.0):
                self.smoothing = smoothing
            def fit(self, X, y):
                N = X.shape[0]
                n_{words} = X.shape[1]
                V = np.arange(n_words)
                prior = np.asarray([1 - np.count_nonzero(y) / N, np.count_nonzero(y) / N])
                Tct = np.zeros((n_words, 2))
                Tct[:, 0] = np.sum(X[y == 0], axis=0)
                Tct[:, 1] = np.sum(X[y == 1], axis=0)
                sum_term = (Tct + self.smoothing)
                cond_prob = sum_term / (np.sum(sum_term, axis=0))
                self.V_{-} = V
                self.prior_ = prior
                self.cond_prob_ = cond_prob
                return self
            def predict(self, X):
                score = np.tile(self.prior_, (X.shape[0], 1))
                for i in range(X.shape[0]):
                    score[i, :] += np.sum(np.log(self.cond_prob_[np.flatnonzero(X[i,:]), :]),
                                           axis=0)
                return np.argmax(score, axis=1)
            def score(self, X, y):
                return np.mean(self.predict(X) == y)
In [8]: # Test our homemade NB
        nb = NB()
```

```
nb.fit(X[::2], y[::2])
score = nb.score(X[1::2], y[1::2])
print("Score : ", score)
Score : 0.836
```

2.4 Question 4

Evaluer les performances de votre classifieur en cross-validation 5-folds

```
In [9]: n_folds = 5
In [10]: from sklearn.model_selection import cross_val_score
In [11]: scores = cross_val_score(nb, X, y, cv=n_folds)
In [12]: scores
Out[12]: array([ 0.825 ,  0.825 ,  0.8125,  0.8375,  0.825 ])
```

2.5 Question 5

Modifier la fonction count_words pour qu'elle ignore les stop words dans le fichier data/english.stop. Les performances sont-elles améliorées ?

```
In [13]: filename_stop = 'data/english.stop'
         stop_words = set(open(filename_stop).read().split())
In [14]: def count_words_improved(texts, stop_words=stop_words):
             """Vectorize text : return count of each word in the text snippets
             Parameters
             _____
             texts : list of str
                 The texts
             stop_words : set of str
                 The stop words
             Returns
             _____
             vocabulary : dict
                 A dictionary that points to an index in counts for each word.
             counts : ndarray, shape (n_samples, n_features)
                 The counts of each word in each text.
                 n_samples == number of documents.
                 n_features == number of words in vocabulary.
             11 11 11
```

```
words = set(' '.join(texts).split()) - stop_words

n_features = len(words)
n_samples = len(texts)
counts = np.zeros((n_samples, n_features))

# Build vocabulary dictionary - key : word , value : column index in counts array
vocabulary = { word : i for i, word in enumerate(sorted(words)) }

# Build counts
for l, text in enumerate(texts, 0):
    st = text.split()
    filtered_words = [word for word in st if word not in stop_words]
    for w in filtered_words:
        counts[l, vocabulary[w]] +=1
return vocabulary, counts
```

2.5.1 Test sur un jeu de données simple

```
In [15]: vocabulary_sample_improved, X_sample_improved = count_words_improved(text_sample)
        print("--- Vocabulary sample improved")
        print(vocabulary_sample_improved)
        import pandas as pd
        df_sample_improved = pd.DataFrame(X_sample_improved, columns=sorted(vocabulary_sample_i
        print()
        print("--- X sample improved")
        print(df_sample_improved)
--- Vocabulary sample improved
{'fun': 6, 'Christmas': 0, 'coming': 4, 'love': 7, 'Telecom': 3, 'world': 8,
'Hello': 1, 'I': 2, 'cool': 5}
--- X sample improved
  Christmas Hello
                      I Telecom coming cool fun love world
0
        0.0
               1.0 0.0
                             0.0
                                    0.0
                                          0.0 0.0
                                                     0.0
                                                            1.0
                                                           1.0
1
        0.0
               1.0 0.0
                            1.0
                                    0.0 0.0 0.0
                                                   0.0
2
        1.0
               1.0 1.0
                            0.0
                                    0.0 0.0 0.0
                                                    1.0
                                                           0.0
3
        1.0
               0.0 0.0
                            0.0
                                    1.0
                                          0.0 0.0 0.0
                                                           0.0
4
        1.0
               0.0 0.0
                            0.0
                                    0.0
                                          1.0 1.0
                                                     0.0
                                                           0.0
```

Les mots tels que { "is", "and" } sont bien retirés du wordcount. En comparaison, dans notre première version de la fonction, nous avions le résultat suivant :

```
--- X sample
  Christmas
            Hello
                     I Telecom and
                                      coming
                                              cool
                                                    fun
                                                         is love world
0
        0.0
               1.0 0.0
                            0.0 0.0
                                         0.0
                                               0.0
                                                    0.0 0.0
                                                              0.0
                                                                     1.0
        0.0
               1.0 0.0
                            1.0 1.0
                                         0.0
                                               0.0 0.0 0.0
                                                              0.0
                                                                     1.0
1
2
               1.0 1.0
                            0.0 0.0
                                                              1.0
                                                                     0.0
        1.0
                                         0.0
                                               0.0 0.0 0.0
3
        1.0
               0.0 0.0
                            0.0 0.0
                                         1.0
                                               0.0 0.0 1.0
                                                              0.0
                                                                     0.0
        1.0
               0.0 0.0
                            0.0 1.0
                                         0.0
                                               1.0 1.0 1.0
                                                              0.0
                                                                     0.0
```

Quant aux autres mots, les valeurs dans la matrice restent bien inchangées.

2.5.2 Test sur les données réelles

```
In [17]: # Count words in text
        vocabulary_improved, X_improved = count_words_improved(texts, stop_words)
In [18]: # Test our homemade NB
        nb_stop_words = NB()
        nb_stop_words.fit(X_improved[::2], y[::2])
         score_stop_words = nb_stop_words.score(X_improved[1::2], y[1::2])
        print("Score : ", score_stop_words)
Score: 0.832
In [19]: # We can also do a cross validation here
         scores_stop_words = cross_val_score(nb_stop_words, X_improved, y, cv=n_folds)
In [20]: scores_stop_words
Out[20]: array([ 0.8175,  0.8275,  0.8325,  0.8525,  0.8125])
In [21]: print("Score with stop words : ", score)
        print("Score without stop words : ", score_stop_words)
        print()
        print("Cross validation scores with stop words : ", scores)
        print("Cross validation scores without stop words : ", scores_stop_words)
Score with stop words: 0.836
Score without stop words : 0.832
Cross validation scores with stop words: [ 0.825 0.825
                                                            0.8125 0.8375 0.825 ]
Cross validation scores without stop words: [ 0.8175  0.8275  0.8325  0.8525  0.8125]
```

On obtient donc un meilleur score lorsqu'on prend en compte les stop words dans le word count. La différence n'est cependant pas significative. Compte tenu de la faible différence, on

peut se demander si les stop words rajoutent du bruit, c'est-à-dire qu'ils ne contribuent pas majoritairement à la détermination d'une classe de documents.

Cependant, on peut remarquer que certains stop words peuvent probablement nuancer une opinion et ainsi avoir un impact sur la classification d'un document. Les connecteurs logiques d'opposition tels que "However" peuvent en effet nuancer une opinion et donner l'aspect négatif du texte, ainsi que les verbes à la forme négative tels que "don't".

3 UTILISATION DE SCIKIT-LEARN

```
In [22]: n_folds = 5
```

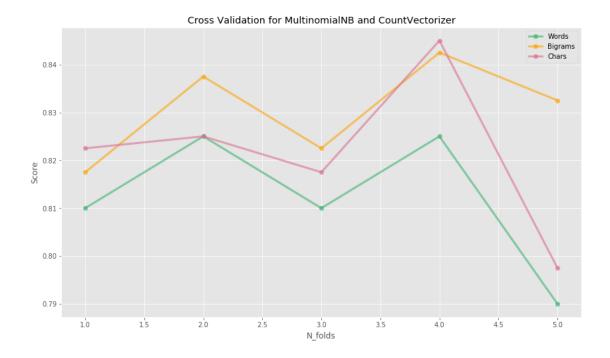
3.1 Question 1

Comparer votre implémentation avec scikit-learn

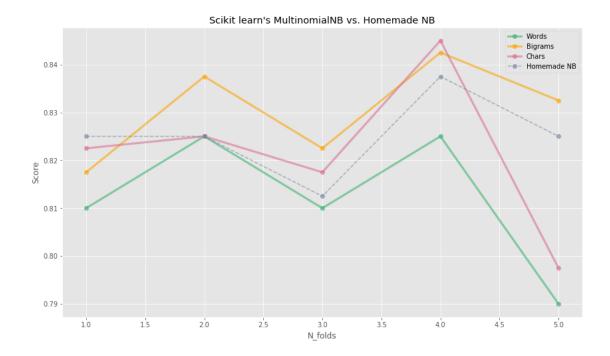
```
In [23]: from sklearn.naive_bayes import MultinomialNB
         from sklearn.pipeline import Pipeline
         from sklearn.feature_extraction.text import CountVectorizer
In [24]: model_nb = MultinomialNB()
         def apply_pipeline(model=model_nb, text=texts, y=y, ngram_range=(1, 1),
                            analyzer='word', n_folds=5):
             """Create a pipeline for model and a cross validation
             Parameters
             _____
             model : a sklearn model
                 The model
             texts : list of str
                 The texts
             ngram_range : tuple
                 The ngram range for the CountVectorizer
             analyze: str
                 The analyzer for the CountVectorizer
             n_{-} fold : int
                 the number of folds for the cross validation
             Returns
             _____
             scores : list of floats
                 The obtained score after cross validation
             elapsed: list of float
                 The time elapsed during execution
             start = time.time()
             pipeline = Pipeline([
```

```
('counts', CountVectorizer(ngram_range=ngram_range, analyzer=analyzer)),
             ('classifier', model)
             ])
             scores = cross_val_score(pipeline, text, y, cv=n_folds)
             end = time.time()
             elapsed = end - start
             return scores, elapsed
In [25]: def test_model(model=model_nb, text=texts, y=y, n_folds=5):
             """Apply pipeline and cross validation for analyzers words, bigrams, and chars
             Parameters
             model : a sklearn model
                 The model
             texts : list of str
                 The texts
             n_{-} fold : int
                 the number of folds for the cross validation
             Returns
             _____
             scores : lists of floats
                 The obtained scores for the three tests
             elapsed : list of float
                 The time elapsed during execution
             # Words
             print("--- Words")
             scores_w, elapsed_w = apply_pipeline(model=model, text=text, y=y,
                                                   n_folds=n_folds)
                        | Scores: ", scores_w)
             print("
                        | Accuracy: %0.2f (+/- %0.2f)" % (scores_w.mean(), scores_w.std() * 2))
             print("
                       | Time elapsed (s): ", elapsed_w)
             print("
             # Bigrams
             print("--- Bigrams")
             scores_b, elapsed_b = apply_pipeline(model=model, text=text, y=y,
                                                   ngram_range=(1, 2), analyzer='word',
                                                   n_folds=n_folds)
             print("
                        | Scores: ", scores_b)
                        | Accuracy: %0.2f (+/- %0.2f)" % (scores_b.mean(), scores_b.std() * 2))
             print("
             print("
                       | Time elapsed (s): ", elapsed_b)
             # Char
             print("--- Chars")
```

```
scores_c, elapsed_c = apply_pipeline(model=model, text=text, y=y,
                                                  ngram_range=(3, 6), analyzer='char',
                                                  n_folds=n_folds)
             print("
                        | Scores: ", scores_c)
                        | Accuracy: %0.2f (+/- %0.2f)" % (scores_c.mean(), scores_c.std() * 2))
             print("
             print("
                        | Time elapsed (s): ", elapsed_c)
             return [scores_w, scores_b, scores_c], [elapsed_w, elapsed_b, elapsed_c]
In [26]: [scores_w, scores_b, scores_c], [elapsed_w, elapsed_b, elapsed_c] = test_model()
--- Words
    | Scores: [ 0.81  0.825  0.81  0.825  0.79 ]
    | Accuracy: 0.81 (+/- 0.03)
    | Time elapsed (s): 7.997492074966431
--- Bigrams
    | Scores: [ 0.8175  0.8375  0.8225  0.8425  0.8325]
    | Accuracy: 0.83 (+/- 0.02)
    | Time elapsed (s): 33.28206276893616
--- Chars
    | Scores: [ 0.8225  0.825
                                 0.8175 0.845
                                                 0.7975]
    | Accuracy: 0.82 (+/- 0.03)
    | Time elapsed (s): 391.97445607185364
In [27]: scores_nb = [scores_w, scores_b, scores_c]
3.1.1 Résultats obtenus avec Scikit Learn
In [28]: # Plot all
         plt.plot(np.arange(n_folds) + 1, scores_w, linewidth=lw, alpha=alp,
                  marker='o', color="mediumseagreen", label='Words')
         plt.plot(np.arange(n_folds) + 1, scores_b, linewidth=lw, alpha=alp,
                  marker='o', color="orange", label='Bigrams')
         plt.plot(np.arange(n_folds) + 1, scores_c, linewidth=lw, alpha=alp,
                  marker='o', color="palevioletred", label='Chars')
         plt.xlabel("N_folds")
         plt.ylabel("Score")
         plt.title("Cross Validation for MultinomialNB and CountVectorizer")
         plt.legend()
         plt.show()
         plt.close()
```



3.1.2 Comparaison avec notre implémentation



Le graphique ci-dessus présente les courbes obtenues avec l'implémentationde Naive Bayes de Scikit Learn, ainsi que la courbe obtenue dans la partie précédente avec notre propre implémentation du modèle. - D'une part les résultats obtenus avec Scikit learn semblent globalement meilleurs qu'avec notre implémentation (avec Bigrams et Chars) - D'autre part on remarque des différences entre les différents types d'analyzer. Les valeurs de scores sont plus élevées avec Bigrams et Chars qu'avec Words

Les scores obtenus avec les bigrammes sont visiblement meilleurs que pour les chars et les mots. L'idée de prendre en compte les bigrammes et d'obtenir la probabilité qu'un mot A apparaisse dans notre extrait, suivi du mot B. La fréquence de distribution d'un bigramme dans une chaine permet de déterminer la probabilité d'un token, connaissant le token précédent.

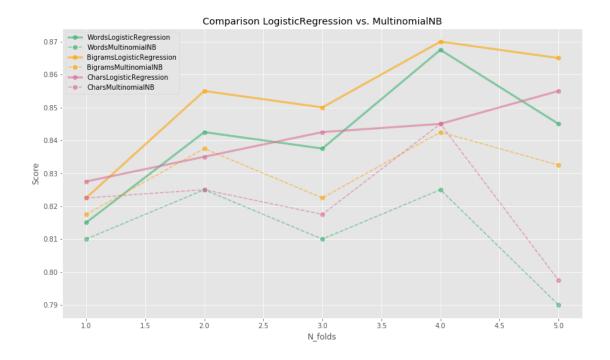
En prenant en compte les chaînes de caractères, les scores sont moins bons que pour les mots et les bigrammes. Contrairement aux bigrammes où la prise en compte de l'enchaînement des mots améliore de score, la prise en compte de sous-chaines de caractères seules et non de probabilités de succession d'une autre chaîne dégrade les résultats.

Les graphiques ci-dessus permettent de visualiser les courbes de score, ainsi que les valeurs d'écart-type associées. On remarque que l'écart-type de la dernière courbe - correspondont à l'analyzer char - est plus bas que dans les deux autres cas.

3.2 Question 2

```
marker='o', color="orange", label='Bigrams' + model_name1)
            plt.plot(np.arange(n_folds) + 1, scores2[1], '--', linewidth=lw/2, alpha=alp,
                     marker='o', color="orange", label='Bigrams' + model_name2)
            plt.plot(np.arange(n_folds) + 1, scores1[2], linewidth=lw, alpha=alp,
                     marker='o', color="palevioletred", label='Chars' + model_name1)
            plt.plot(np.arange(n_folds) + 1, scores2[2], '--', linewidth=lw/2, alpha=alp,
                     marker='o', color="palevioletred", label='Chars' + model_name2)
            plt.xlabel("N_folds")
            plt.ylabel("Score")
            title = "Comparison " + model_name1 + " vs. " + model_name2
            plt.title(title)
            plt.legend()
            plt.show()
            plt.close()
3.2.1 Logistic regression
In [31]: from sklearn.linear_model import LogisticRegression
        # Test with Logistic Regression
        model_lr = LogisticRegression()
        [scores_w_lr, scores_b_lr, scores_c_lr],
        [elapsed_w_lr, elapsed_b_lr, elapsed_c_lr] = test_model(model=model_lr)
--- Words
    | Accuracy: 0.84 (+/-0.03)
    | Time elapsed (s): 27.586987018585205
--- Bigrams
    | Scores: [ 0.8225  0.855
                                0.85
                                       0.87
                                               0.865 ]
    | Accuracy: 0.85 (+/- 0.03)
    | Time elapsed (s): 116.26668787002563
--- Chars
    | Scores: [ 0.8275  0.835
                                0.8425 0.845
                                               0.855]
    | Accuracy: 0.84 (+/- 0.02)
    | Time elapsed (s): 613.3107368946075
In [32]: # Compare LogisticRegression with MultinomialNB
        scores_lr = [scores_w_lr, scores_b_lr, scores_c_lr]
        plot_comparison(scores_lr, scores_nb, "LogisticRegression", "MultinomialNB")
```

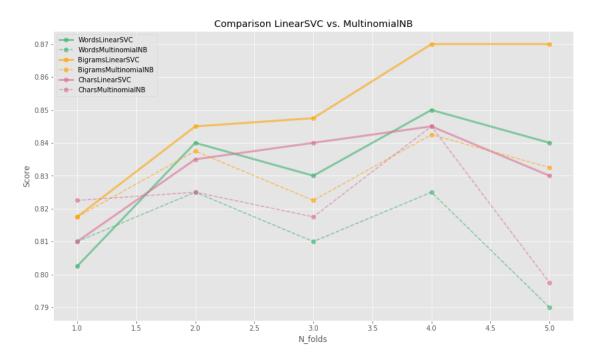
plt.plot(np.arange(n_folds) + 1, scores1[1], linewidth=lw, alpha=alp,



Avec LogisticRegression on obtient de meilleurs résultats dans les trois cas (Words, Bigrams, Chars) qu'avec MultinomialNB.

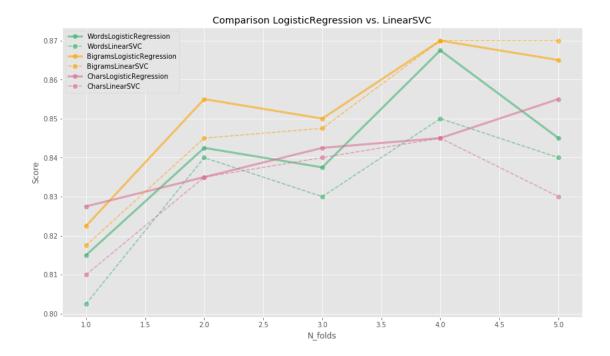
3.2.2 Linear SVC

```
In [33]: from sklearn.svm import LinearSVC
         # Test with LinearSVC
        model_svc = LinearSVC()
         [scores_w_svc, scores_b_svc, scores_c_svc],
         [elapsed_w_svc, elapsed_b_svc, elapsed_c_svc] = test_model(model=model_svc)
--- Words
    | Scores: [ 0.8025  0.84
                                 0.83
                                        0.85
                                                0.84 ]
    | Accuracy: 0.83 (+/- 0.03)
    | Time elapsed (s): 15.670583009719849
--- Bigrams
    | Scores: [ 0.8175  0.845
                                0.8475 0.87
                                                0.87
    | Accuracy: 0.85 (+/- 0.04)
    | Time elapsed (s): 147.2756040096283
--- Chars
    | Scores: [ 0.81
                       0.835 0.84
                                      0.845 0.83 ]
    | Accuracy: 0.83 (+/- 0.02)
    | Time elapsed (s): 569.5203940868378
```



Avec LinearSVC on obtient de meilleurs résultats dans les trois cas (Words, Bigrams, Chars) qu'avec MultinomialNB.

3.2.3 Logistic Regression / LinearSVC



On a démontré au-dessus que les modèles LogisticRegression et LinearSVC mènent tous les deux à de meilleurs scores de prédiction que MultinomialNB. Les deux modèles permetttent en effet de tenir compte des dépendances entre les attributs, et donc en particulier dans une analyse sémantique, d'où les meilleurs résultats. En comparant désormais les deux modèles, on remarque que LogisticRegression obtient dans l'ensemble de meilleurs scores que LinearSVC dans le cadre de nos données.

Dans la suite du TP nous poursuivrons avec MultinomialNB et LinearSVC (par choix).

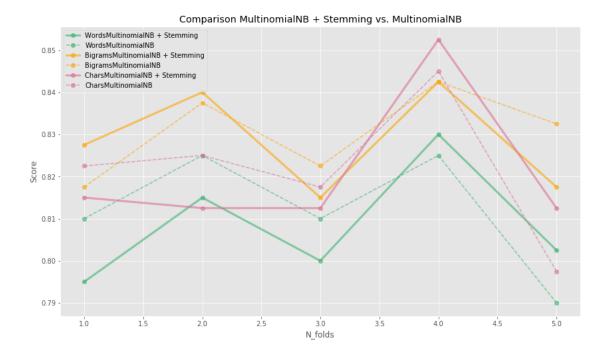
3.3 Question 3

Utiliser la libraire NLTK afin de procéder à une racinisation (stemming). Vous utiliserez la classe SnowballStemmer

```
return stemmed
3.3.1 Test sur un texte simple
In [39]: simple = ["I eat he eats", "She loves eating"]
         simple_stemmed = stem(texts=simple)
         print(simple_stemmed)
['i eat he eat ', 'she love eat ']
3.3.2 Test sur les données réelles
In [40]: stemmed = stem()
3.3.3 MultinomialNB
In [41]: [scores_w_stm, scores_b_stm, scores_c_stm],
 [elapsed_w_stm, elapsed_b_stm, elapsed_c_stm] = test_model(text=stemmed)
--- Words
    | Scores: [ 0.795  0.815
                                 0.8
                                         0.83
                                                 0.8025]
    | Accuracy: 0.81 (+/- 0.03)
    | Time elapsed (s): 8.297225952148438
--- Bigrams
    | Scores: [ 0.8275  0.84
                                 0.815
                                         0.8425 0.8175]
    | Accuracy: 0.83 (+/- 0.02)
    | Time elapsed (s): 45.853594064712524
--- Chars
    | Scores: [ 0.815  0.8125  0.8125  0.8525  0.8125]
    | Accuracy: 0.82 (+/-0.03)
    | Time elapsed (s): 333.6116421222687
In [42]: # Compare new scores with stemming with original MultinomialNB
         scores_stm = [scores_w_stm, scores_b_stm, scores_c_stm]
         plot_comparison(scores_stm, scores_nb, "MultinomialNB + Stemming", "MultinomialNB")
```

for word in words:

stemmed[i] += stemmer.stem(word) + ' '



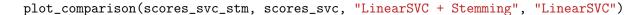
Les scores obtenus après une cross validation avec la racinisation sont globalement plus faibles qu'auparavant.

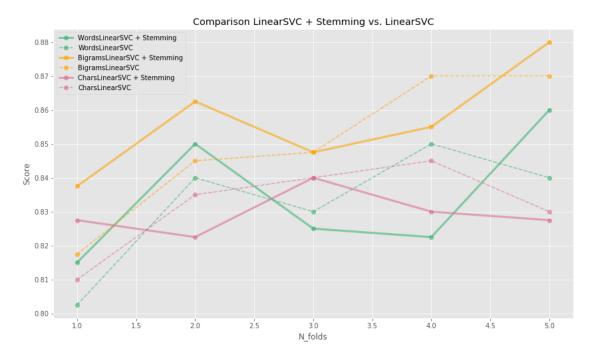
La racinisation coupe les mots écrits sous leur forme exacte et produit des bases de mots pour la classification. Cependant, les détails associés à a forme exacte du mots peuvent jouer un rôle primordial dans le texte. La racinisation dégrade alors la classification.

3.3.4 LinearSVC

```
In [43]: [scores_w_svc_stm, scores_b_svc_stm, scores_c_svc_stm],
[elapsed_w_svc_stm, elapsed_b_svc_stm, elapsed_c_svc_stm] = test_model(model=model_svc,
text=stemmed)
--- Words
    | Scores: [ 0.815
                         0.85
                                 0.825
                                         0.8225 0.86 ]
    | Accuracy: 0.83 (+/- 0.03)
    | Time elapsed (s): 13.600510120391846
--- Bigrams
    | Scores: [ 0.8375  0.8625  0.8475  0.855
                                                 0.88 ]
    | Accuracy: 0.86 (+/- 0.03)
    | Time elapsed (s): 50.19047284126282
--- Chars
    | Scores: [ 0.8275  0.8225
                                         0.83
                                                 0.8275]
    | Accuracy: 0.83 (+/- 0.01)
    | Time elapsed (s): 564.7897400856018
In [44]: # Compare new scores with stemming with original MultinomialNB
```

scores_svc_stm = [scores_w_svc_stm, scores_b_svc_stm, scores_c_svc_stm]





Dans le cas de LinearSVC, la racinisation amène à des scores relativement satisfaisants par rapport au modèle LinearSVC de bas. Cela peut s'expliquer par le fait que le modèle prend en compte les dépendances entre les attributs, ce qui mène à des résultats améliorés dans le cas d'une analyse sémantique.

3.4 Question 4

Filtrer les mots par catégorie grammaticale (POS : Part Of Speech) et ne garder que les noms, les verbes, les adverbes et les adjectifs pour la classification

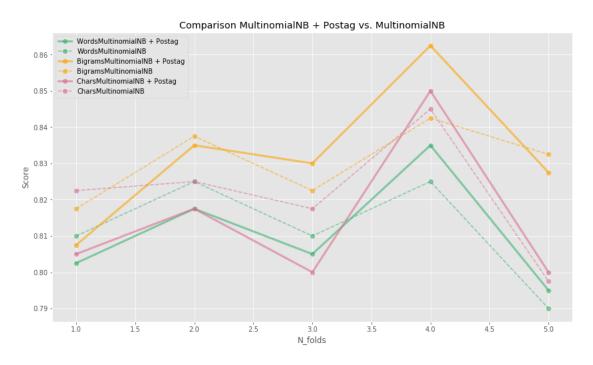
```
return filtered
         def apply_pos_tag(filtered):
             postagged = []
             for i, tuples in enumerate(filtered, 0):
                 postagged.append('')
                 for t in tuples:
                     postagged[i] += t[0] + ' '
             return postagged
3.4.1 Test sur un texte simple
In [47]: simple_new = ["Today is a beautiful day",
                                                       "Christmas is coming",
 "Tonight is freezing and cold"]
         pos_simple = filter_pos(texts=simple_new)
         print(pos_simple)
[[('Today', 'NOUN'), ('is', 'VERB'), ('beautiful', 'ADJ'), ('day', 'NOUN')],
 [('Christmas', 'NOUN'), ('is', 'VERB'), ('coming', 'VERB')], [('Tonight', 'NOUN'),
  ('is', 'VERB'), ('freezing', 'VERB'), ('cold', 'ADJ')]]
In [48]: postagged_simple = apply_pos_tag(pos_simple)
         print(postagged_simple)
['Today is beautiful day ', 'Christmas is coming ', 'Tonight is freezing cold ']
3.4.2 Test sur les données réelles
In [49]: filtered = filter_pos()
In [50]: postagged = apply_pos_tag(filtered)
3.4.3 MultinomialNB
In [51]: [scores_w_pst, scores_b_pst, scores_c_pst],
 [elapsed_w_pst, elapsed_b_pst, elapsed_c_pst] = test_model(text=postagged)
--- Words
    | Scores: [ 0.8025  0.8175  0.805  0.835
                                                 0.795 ]
    | Accuracy: 0.81 (+/- 0.03)
    | Time elapsed (s): 5.83814001083374
--- Bigrams
    | Scores: [ 0.8075  0.835
                                 0.83
                                         0.8625 0.8275]
    | Accuracy: 0.83 (+/- 0.04)
    | Time elapsed (s): 25.249979972839355
--- Chars
```

| Scores: [0.805 0.8175 0.8 0.85 0.8]

| Accuracy: 0.81 (+/- 0.04)

| Time elapsed (s): 206.31769680976868

plot_comparison(scores_pst, scores_nb, "MultinomialNB + Postag", "MultinomialNB")

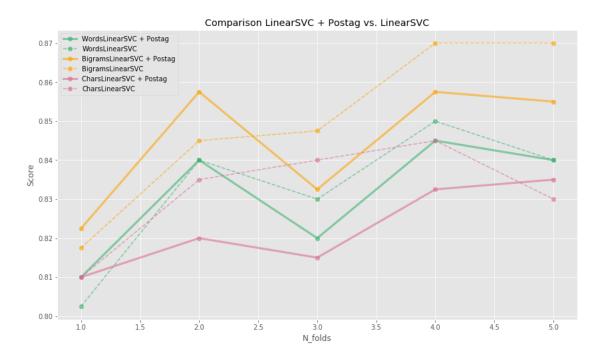


3.4.4 LinearSVC

In [53]: [scores_w_svc_pst, scores_b_svc_pst, scores_c_svc_pst],
[elapsed_w_svc_pst, elapsed_b_svc_pst, elapsed_c_svc_pst] = test_model(model=model_svc, text=post)

```
--- Words
    | Scores: [ 0.81
                               0.82
                                      0.845 0.84]
                        0.84
    | Accuracy: 0.83 (+/- 0.03)
    | Time elapsed (s): 9.077815055847168
--- Bigrams
    | Scores: [ 0.8225  0.8575  0.8325  0.8575  0.855 ]
    | Accuracy: 0.84 (+/- 0.03)
    | Time elapsed (s): 51.60603308677673
--- Chars
    | Scores: [ 0.81
                         0.82
                                 0.815
                                         0.8325 0.835 ]
    | Accuracy: 0.82 (+/- 0.02)
```

| Time elapsed (s): 329.51761507987976

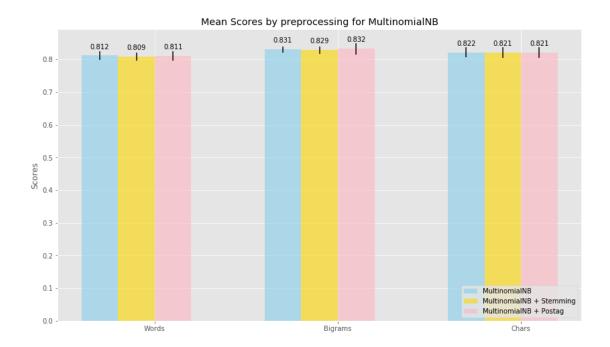


De manière générale, les résultats obtenus avec pos_tag sont moins bons que les résultats obtenus avec le modèle d'origine, pour le modèle MultinomialNB comme pour LinearSVC. Le filtrage des mots par catégorie grammaticale ne semble pas améliorer les resultats de classification.

3.5 Récapitulatif

3.5.1 --- Scores

```
width = 0.2
rects1 = ax.bar(ind, [mean(1) for l in models_originals],
                width, alpha=alp, label='MultinomialNB', color='skyblue',
                yerr=[np.std(l) for l in models_originals])
rects2 = ax.bar(ind + width, [mean(1) for 1 in models_stemming],
                width, alpha=alp, label='MultinomialNB + Stemming', color='gold',
                yerr=[np.std(l) for l in models_stemming])
rects3 = ax.bar(ind + 2 * width, [mean(1) for 1 in models_postag],
                width, alpha=alp, label='MultinomialNB + Postag', color='lightpink',
                yerr=[np.std(1) for 1 in models_postag])
# add some text for labels, title and axes ticks
ax.set_ylabel('Scores')
ax.set_title('Mean Scores by preprocessing for MultinomialNB')
ax.set_xticks(ind + 3 * width / 2)
ax.set_xticklabels(('Words', 'Bigrams', 'Chars'))
def autolabel(rects):
    Attach a text label above each bar displaying its height
    for rect in rects:
        height = rect.get_height()
        ax.text(rect.get_x() + rect.get_width()/2., 1.02*height,
                '%.3f' % height,
                ha='center', va='bottom')
autolabel(rects1)
autolabel(rects2)
autolabel(rects3)
plt.legend(loc="lower right")
plt.show()
```

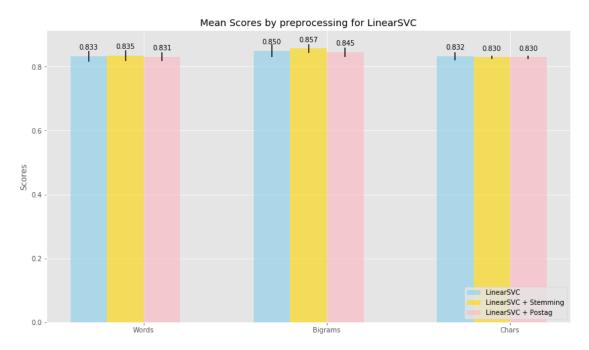


Bien que l'on obtient des valeurs de score différentes selon les modèles utilisés durant cette partie, les valeurs ont des ordres de grandeur tout à fait similaires. Des traitements des données avant l'utilisation du modèle, comme la racinisation, semblent toutefois diminuer le score final. En comparaison avec le Naive Bayes, LinearSVC amène à de meilleurs scores sur nos données.

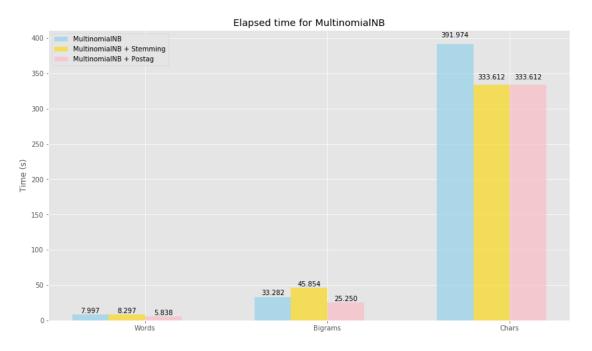
```
In [58]: fig, ax = plt.subplots()
         ind = np.arange(len(models_originals))
         width = 0.2
         rects1_svc = ax.bar(ind, [mean(1) for 1 in models_svc],
                         width, alpha=alp, label='LinearSVC', color='skyblue',
                         yerr=[np.std(l) for l in models_svc])
         rects2_svc = ax.bar(ind + width, [mean(1) for 1 in models_svc_stemming],
                         width, alpha=alp, label='LinearSVC + Stemming', color='gold',
                         yerr=[np.std(l) for l in models_svc_stemming])
         rects3_svc = ax.bar(ind + 2 * width, [mean(1) for 1 in models_svc_postag],
                         width, alpha=alp, label='LinearSVC + Postag', color='lightpink',
                         yerr=[np.std(1) for 1 in models_svc_postag])
         # add some text for labels, title and axes ticks
         ax.set_ylabel('Scores')
         ax.set_title('Mean Scores by preprocessing for LinearSVC')
         ax.set_xticks(ind + 3 * width / 2)
         ax.set_xticklabels(('Words', 'Bigrams', 'Chars'))
```

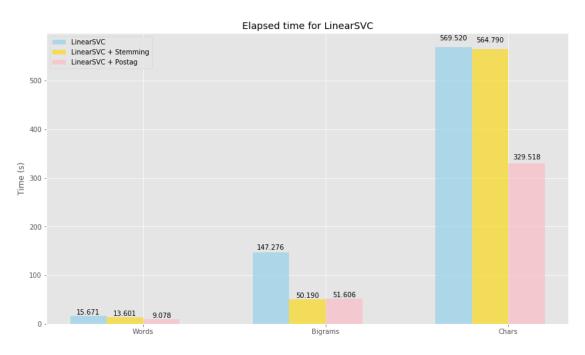
```
autolabel(rects1_svc)
autolabel(rects2_svc)
autolabel(rects3_svc)

plt.legend(loc="lower right")
plt.show()
```



3.5.2 --- Temps d'exécution





Le temps d'exécution des modèles pour les caractères est largement plus élevé que pour les mots et les bigrammes. Cela est dû au grand nombre de données supplémentaires à prendre en compte en considérant les sous-chaînes de caractères.